

Evaluación del potencial de los LLMs en tareas de ofuscación y desofuscación de código

Autor: Gabriel López Ormeño
Tutor: Alberto Ballesteros Rodríguez
Titulación: Grado en Ingeniería en Sistemas de Información

1. Introducción

En el ámbito del desarrollo de software y la ciberseguridad existen técnicas utilizadas para dificultar o facilitar la compresión de código, como son la ofuscación y desofuscación de código.

Antes de la aparición de la inteligencia artificial para estas tareas se empleaban métodos tradicionales, como las transformaciones sintácticas y estructurales, o en el caso de la desofuscación, los métodos heurísticos que combinan descompiladores y reconocimiento de patrones.ⁱ

No obstante, ahora los modelos de lenguaje a gran escala (LLMs) han crecido enormemente en el análisis y compresión de texto, lo que ha llevado a que se abra la posibilidad de aplicarlos en la ofuscación de código.ⁱⁱ

Ya existen algunos estudios en los que se ha experimentado con los LLMs y sus capacidades para reconstruir código, comentando sus beneficios y barreras.ⁱⁱⁱ

En este trabajo se propone analizar el desempeño de diferentes LLMs en la ofuscación y desofuscación de código de una manera sistemática, comparando con los métodos tradicionales. Pudiendo obtener unos resultados completos y detallados mediante la utilización de diferentes datasets y estrategias.

2. Objetivos y campo de aplicación

Objetivo general

Evaluar la capacidad de diferentes LLMs para ofuscar y desofuscar código, estableciendo un marco comparativo con los métodos tradicionales.

Objetivos específicos

- Desarrollar un framework que permita automatizar la aplicación de LLMs sobre los datasets.
- Implementar un conjunto de pruebas para analizar la eficacia de los LLMs en escenarios zero-shot y few-shot.
- Comparar el rendimiento frente a las técnicas conocidas, evaluando ventajas y limitaciones.
- Observar el comportamiento de distintos LLMs, considerando tanto aquellos orientados a código como otros de propósito general.
- Establecer una comparativa de resultados entre las dos direcciones del flujo de trabajo (ofuscación y desofuscación).

El campo de aplicación del proyecto abarca la ingeniería software, la ciberseguridad y la inteligencia artificial, enfocándose especialmente en la protección de código y la automatización de su análisis y otros procesos.

3. Descripción del trabajo

El proyecto consistirá en la creación de un framework que permita evaluar de manera automatizada la capacidad de los LLMs para ofuscar y desofuscar código. Se emplearán datasets contruidos de forma manual, consistentes de código original y código ofuscado mediante técnicas conocidas.

El script original se clasificará en tamaño pequeño (10-20 líneas) o grande (50-80 líneas) para evaluar el impacto de la longitud en el rendimiento del modelo. Cada script original será ofuscado utilizando alguna librería, como pyarmor u otras de renombrado de variables, inserción de código muerto, transformaciones.

Se analizarán diferentes tipos de modelos, tanto generales como especializados en código (por ejemplo, LLaMA y CodeLLaMA), implementando pruebas en distintos modos:

- Zero-shot: donde el modelo recibe la tarea sin ejemplos previos.
- Few-shot: proporcionando ejemplos para guiar su comportamiento.

Para todo esto es fundamental el empleo de la librería LangChain^{iv} y la herramienta Ollama^v para facilitar la conexión con los modelos a utilizar y optimizar su gestión y empleo en el programa.

Será necesario aplicar técnicas de prompt engineering para cada uno de los LLMs. De manera que se utilizarán los prompts más eficaces para maximizar el rendimiento de los modelos, además, estos serán redactados en inglés por este mismo motivo.

La evaluación del código estará compuesta por dos partes:

- Similitud estructural: utilizando análisis de árboles sintácticos (ASTs) para comparar la estructura del código generado con el original, la lógica y la organización.
- Funcionalidad: mediante la ejecución de los scripts, estableciendo límites de tiempo.

4. Metodología y plan de trabajo

Aunque no se vaya a incluir como etapa específica secuencial del plan del trabajo, comentar que la redacción de la memoria se estará llevando a cabo durante todo el plan de manera paralela.

1. Revisión bibliográfica y estado del arte

- Búsqueda de documentación de interés en fuentes académicas sobre LLMs y desofuscación de código.
- Estudio de librerías y frameworks para la integración de los modelos.

2. Selección y análisis de herramientas

- Tras evaluar, se seleccionan las librerías que más se adapten a nuestras necesidades y entorno.

3. Desarrollo del prototipo

- Implementación del framework para evaluar la ofuscación de código de los LLMs.

4. Ejecución de las pruebas

- Ejecución con prompts pensados previamente sobre los datasets contruidos, garantizando lograr los objetivos.
- Análisis preliminar del comportamiento de los modelos ante los distintos niveles y escenarios establecidos.

5. Generación de métricas y análisis

- Comparación de resultados obtenidos con métodos tradicionales.

6. Bibliografía

ⁱ Raitsis, T., Elgazari, Y., Toibin, G. E., Lurie, Y., Mark, S., & Margalit, O. (2025). Code Obfuscation: A Comprehensive Approach to Detection, Classification, and Ethical Challenges. *Algorithms*, 18(2), 54. <https://doi.org/10.3390/a18020054>

ⁱⁱ Nikiema, S.L., Samhi, J., Kabor'e, A.K., Klein, J., & Bissyand'e, T.F. (2025). The Code Barrier: ¿What LLMs Actually Understand? *ArXiv*, abs/2504.10557. <https://doi.org/10.48550/arXiv.2504.10557>

ⁱⁱⁱ Hajipour, H., Bardin, S., Schönherr, L., Beste, D., Menguy, G., Fritz, M., Cinà, A. E., Holz, T., & Eisenhofer, T. (2025). Exploring the potential of LLMs for code deobfuscation. *Detection of Intrusions and Malware, and Vulnerability Assessment: 22nd International Conference, DIMVA, Lecture Notes in Computer Science* (pp. 267–286). Springer. https://doi.org/10.1007/978-3-031-97620-9_15

^{iv} LangChain Documentation. *LangChain*. (s.f.). Recuperado el 21 de diciembre de 2025. <https://docs.langchain.com>

^v Ollama Documentation. *Ollama*. (s.f.). Recuperado el 21 de diciembre de 2025. <https://docs.ollama.com>